

F5-TTS API 接口文档

本文档详细说明了 F5-TTS FastAPI 服务提供的 HTTP 接口。

基础信息

- 默认端口：8008 (Docker 部署时建议映射)
- 生产环境：https://tts.duomi365.work:91
- 基础路径：/
- 认证：API Key 认证 (Header X-API-Key)

安全认证 (Security)

为了保护服务接口，生产环境必须启用 API Key 认证。

启用方式

在服务端设置环境变量 F5_TTS_API_KEY，例如：

```
export F5_TTS_API_KEY="your-secret-key-xxx"
```

客户端调用

在所有 POST 请求 (/tts, /tts/batch, /warmup) 中添加 HTTP Header：

X-API-Key: your-secret-key-xxx

若 Key 无效或缺失，将返回：- **401 Unauthorized**: 未提供 Key - **403 Forbidden**: Key 错误

1. 系统接口

1.1 健康检查

用于 Kubernetes 存活探针 (Liveness Probe) 或服务监控。不需要认证。

- **URL**: /health
- **Method**: GET

- 响应示例:

```
{
  "status": "ok",
  "loaded": true,
  "device": "cuda",
  "mel_spec_type": "vocos",
  "model_name": "F5TTS_v1_Base"
}
```

1.2 版本信息

返回当前服务的版本信息。

- **URL**: /version
- **Method**: GET

- 响应示例:

```
{
  "name": "f5-tts",
  "version": "1.1.15"
}
```

1.3 模型预热

显式触发一次短音频生成，用于 Kubernetes 就绪探针（Readiness Probe）或冷启动优化。需要 API Key。

- **URL:** /warmup
- **Method:** POST

- 响应示例:

```
{
  "status": "ok",
  "sample_rate": 24000,
  "duration_sec": 1.5
}
```

2. 语音合成接口 (TTS)

2.1 单次合成

核心接口，支持通过上传文件或 URL 提供参考音频。需要 API Key。

- **URL:** /tts
- **Method:** POST
- **Content-Type:** multipart/form-data 或 application/json

请求参数 (Multipart/Form-Data)

字段名	类型	必填	说明
request	string (JSON)	否	包含文本与生成参数的 JSON 字符串（见下表）
ref_audio	file	否	参考音频文件（WAV/MP3/FLAC），优先级高于 ref_audio_url
gen_text	string	否	待生成的文本（若未在 request JSON 中提供）
ref_text	string	否	参考音频对应的文本（可选，为空则自动识别）
ref_audio_url	string	否	参考音频的可访问 URL

Request JSON 结构:

```
{
  "gen_text": "需要生成的文本",
  "ref_text": "参考音频的文本",
  "ref_audio_url": "http://example.com/ref.wav",
  "params": {
    "nfe_step": 32,
    "cfg_strength": 2.0,
    "speed": 1.0,
    "fix_duration": null
  }
}
```

推理参数 (params 对象)

参数名	类型	默认值	说明
nfe_step	int	32	推理步数，越高质量越好但速度越慢（建议 16-64）
cfg_strength	float	2.0	Classifier-Free Guidance 强度，控制对参考音频的保真度
speed	float	1.0	语速倍率
sway_sampling_coef	float	-1.0	采样系数（通常保持默认）
fix_duration	float	null	固定输出时长（秒），null 为自动计算

响应结构

```
{
  "audio_base64": "UklGRi...", // WAV 格式的 Base64 编码字符串
  "sample_rate": 24000,
  "duration_sec": 3.5,
  "seed": 123456,
  "info": {
    "request_id": "a1b2c3d4",
    "model": "F5TTS_v1_Base",
    "device": "cuda",
    "params": { ... }
  }
}
```

调用示例 (Python)

```
import requests
import json

# 生产环境示例
url = "https://tts.duomi365.work:91/tts"
files = {
  'ref_audio': open('ref.wav', 'rb')
}
data = {
  'gen_text': "你好，世界",
  'ref_text': "这是参考文本",
  # 或者将复杂参数打包为 JSON 字符串
  # 'request': json.dumps({...})
}
response = requests.post(url, files=files, data=data)
result = response.json()
```

2.2 批量合成

用于一次性处理多个请求，受服务端并发队列控制。需要 API Key。

- **URL:** /tts/batch
- **Method:** POST
- **Content-Type:** application/json

请求参数

接收一个数组，每个元素结构同单次请求（不支持文件上传，仅支持 URL 或默认参考音频）。

```
[
  {
    "gen_text": "第一句话",
    "ref_audio_url": "http://example.com/ref1.wav",
    "params": { "speed": 1.0 }
  }
]
```

```
    },
    {
      "gen_text": "第二句话",
      "ref_text": "参考文本",
      "params": { "speed": 1.2 }
    }
  ]
}
```

响应结构

```
{
  "request_id": "batch_123",
  "results": [
    {
      "audio_base64": "...",
      "sample_rate": 24000,
      "duration_sec": 2.1
    },
    {
      "audio_base64": "...",
      "sample_rate": 24000,
      "duration_sec": 3.4
    }
  ]
}
```

错误码

- **200**: 成功
- **401**: 认证失败（未提供 API Key）
- **403**: 权限不足（API Key 错误）
- **422**: 参数校验错误（如缺少 gen_text）
- **500**: 服务端内部错误（如显存不足、模型加载失败）

部署配置

可通过环境变量调整服务行为：

- F5_TTS_API_KEY: API 认证密钥
- ALLOWED_ORIGINS: 允许的 CORS 来源（默认 *）
- ENABLE_TEXT_NORMALIZATION: 是否启用文本标准化（默认 true）- 支持自动处理：数字、日期、时间、货币、车牌号（如“京A88888”）、详细地址（如“北京市朝阳区...”）等。
- MAX_CONCURRENCY: 最大并发请求数（默认 1）
- F5TTS_MODEL: 模型名称（默认 F5TTS_v1_Base）
- F5TTS_DEVICE: 指定设备（cuda, cpu, mps）
- HF_CACHE_DIR: Hugging Face 模型缓存目录