

F5-TTS API 接口文档

本文档详细说明了 F5-TTS FastAPI 服务提供的 HTTP 接口规范。

基础信息

- 默认端口：8008 (Docker 部署时默认暴露端口)
- 生产环境：https://tts.duomi365.work:91
- 基础路径：/
- 认证方式：API Key 认证
 - Header 字段：X-API-Key
 - 环境变量配置：F5_TTS_API_KEY

部署配置 (环境变量)

变量名	默认值	说明
F5_TTS_API_KEY	-	必填。API 认证密钥，用于保护敏感接口。
ALLOWED_ORIGINS	*	允许的 CORS 来源，多个域名用逗号分隔。
ENABLE_TEXT_NORMALIZATION	true	是否启用文本标准化。支持自动处理：数字、日期、时间、货币、车牌号（如“京A88888”）、详细地址（如“北京市朝阳区...”）等。
MAX_CONCURRENCY	1	最大并发请求数，超出限制的请求将排队等待。
F5TTS_MODEL	F5TTS_v1_Base	模型名称。
F5TTS_DEVICE	自动检测	指定推理设备 (cuda, cpu, mps, xpu)。
HF_CACHE_DIR	-	Hugging Face 模型缓存目录。

1. 系统管理接口

1.1 健康检查 (Health Check)

用于 Kubernetes 存活探针 (Liveness Probe) 或服务监控。

- **URL:** /health
- **Method:** GET
- **Auth:** 不需要

响应示例 (200 OK):

```
{
  "status": "ok",
  "loaded": true,           // 模型是否已加载
  "device": "cuda",        // 当前运行设备
  "mel_spec_type": "vocos", // 频谱类型
  "model_name": "F5TTS_v1_Base"
}
```

1.2 版本信息 (Version Info)

获取当前服务的版本信息。

- **URL:** /version
- **Method:** GET
- **Auth:** 不需要

响应示例 (200 OK):

```
{
  "name": "f5-tts",
  "version": "1.1.15"
}
```

1.3 模型预热 (Warmup)

显式触发一次短音频生成（8步推理），用于冷启动优化或验证推理能力。

- **URL:** /warmup
- **Method:** POST
- **Auth:** 需要 (X-API-Key)

响应示例 (200 OK):

```
{
  "status": "ok",
  "sample_rate": 24000,
  "duration_sec": 1.5
}
```

2. 语音合成接口 (TTS)

通用数据结构

InferenceParams (推理参数)

用于控制生成效果的参数对象，所有 TTS 接口均通用。

参数名	类型	默认值	说明
nfe_step	int	32	推理步数。值越大画质/音质越高，但速度越慢。建议范围 16-64。
cfg_strength	float	2.0	Classifier-Free Guidance 强度。控制对参考音频风格的保真度。
speed	float	1.0	语速倍率。1.0 为原速，>1.0 变快，<1.0 变慢。
fix_duration	float	null	强制输出时长（秒）。若设置，将忽略 speed 参数。
target_rms	float	0.1	目标音频的均方根振幅（音量控制）。
cross_fade_duration	float	0.15	拼接片段时的淡入淡出时长（秒）。
sway_sampling_coef	float	-1.0	采样系数。通常保持默认值 -1.0。
seed	int	null	随机种子。若指定，可复现生成结果。

2.1 单次合成 (Single TTS)

核心接口，支持多种方式传入参考音频（文件上传或 URL）。

- **URL:** /tts
- **Method:** POST
- **Auth:** 需要 (X-API-Key)

- **Content-Type:** application/json 或 multipart/form-data

请求方式 A: JSON Body

适用于参考音频为 URL 或使用默认参考音频的场景。

Request Body:

```
{
  "gen_text": "需要生成的文本内容",
  "ref_text": "参考音频对应的文本（可选，为空则自动识别）",
  "ref_audio_url": "http://example.com/ref.wav",
  "params": {
    "nfe_step": 32,
    "speed": 1.0,
    "seed": 42
  }
}
```

请求方式 B: Multipart Form

适用于直接上传参考音频文件的场景。

Form Fields: - gen_text: (string) 待生成文本 - ref_text: (string, 可选) 参考文本 - ref_audio: (file, 可选) 参考音频文件 (.wav, .mp3 等) - request: (string, 可选) 包含复杂参数的 JSON 字符串，例如 {"params": {"nfe_step": 64}}

响应 (200 OK)

```
{
  "audio_base64": "UklGRi...", // WAV 格式音频的 Base64 编码
  "sample_rate": 24000,        // 采样率
  "duration_sec": 3.5,         // 音频时长 (秒)
  "seed": 123456,              // 本次生成使用的种子
  "info": {
    "request_id": "a1b2c3d4",
    "model": "F5TTS_v1_Base",
    "device": "cuda",
    "params": { ... }          // 实际使用的推理参数
  }
}
```

调用示例 (Python)

```
import requests
import json

# 生产环境地址
url = "https://tts.duomi365.work:91/tts"
headers = {"X-API-Key": "YOUR_API_KEY"}

# 方式 1: 上传音频文件
files = {'ref_audio': open('ref.wav', 'rb')}
data = {
  'gen_text': "你好，世界",
  'ref_text': "这是参考音频的文本",
  'request': json.dumps({"params": {"speed": 1.2}}) # 额外参数
}
response = requests.post(url, headers=headers, files=files, data=data)

# 方式 2: 使用 URL
json_payload = {
  "gen_text": "测试文本",
  "ref_audio_url": "http://example.com/ref.wav",
}
```

```
    "params": {"nfe_step": 16}
}
response = requests.post(url, headers=headers, json=json_payload)

result = response.json()
print(f"Generated audio length: {result['duration_sec']}s")
```

2.2 批量合成 (Batch TTS)

用于一次性提交多个合成任务。任务将在服务端按顺序或并发（取决于 MAX_CONCURRENCY）执行。

- **URL:** /tts/batch
- **Method:** POST
- **Auth:** 需要 (X-API-Key)
- **Content-Type:** application/json

请求参数

接收一个数组，每个元素为一个 TTS 请求对象（不支持文件上传，仅支持 URL 或默认参考音频）。

Request Body:

```
[
  {
    "gen_text": "第一句话",
    "ref_audio_url": "http://example.com/ref1.wav",
    "params": { "speed": 1.0 }
  },
  {
    "gen_text": "第二句话",
    "ref_text": "参考文本",
    "params": { "speed": 1.2 }
  }
]
```

响应 (200 OK)

```
{
  "request_id": "batch_123456",
  "results": [
    {
      "audio_base64": "...",
      "sample_rate": 24000,
      "duration_sec": 2.1,
      "seed": 111
    },
    {
      "audio_base64": "...",
      "sample_rate": 24000,
      "duration_sec": 3.4,
      "seed": 222
    }
  ]
}
```

错误码

状态码 含义	说明
200 OK	请求成功
401 Unauthorized	未提供 X-API-Key

- 403** Forbidden 提供的 X-API-Key 无效
- 422** Unprocessable Entity 参数校验错误 (如缺少 `gen_text`)
- 500** Internal Server Error 服务端内部错误 (如模型加载失败、显存不足)